

Решение задачи МАР для марковской сети
типа решётка

Новиков А. В.
МГУ, ВМиК, каф. ММП

31 октября 2012 г.

1 Постановка задачи

Марковские сети применяются практически повсюду. После обучения сети нужно её использовать, то есть решать задачу максимизации апостериорной вероятности. Для большинства реальных задач эта задача NP-сложная. В данной статье проводится обзор существующих state-of-the-art подходов к этой задаче.

2 Методы

Мы остановились на подклассе алгоритмов использующих двойственное разложение. В них задача минимизации исходной энергии сводится к задаче максимизации двойственной энергии (это всегда строго выпуклая функция). Алгоритмы этой группы отличаются конкретным методом максимизации.

- Субградиентный подъём [2]
- Bundle methods [3]
- «Полная декомпозиция»

3 Данные

Для сравнения подходов мы использовали данные опубликованные Karteek Alahari [1]

4 Субградиентный подъём

Результаты работы данного метода зависят от выбора последовательности шагов α_t . После 80 итераций все вариации метода сошлись к примерно одной и той же (на глаз) разметке.

Использовался константный и адаптивный шаг. В случае адаптивного шага использовалась следующая формула:

$$\alpha_t = \frac{Approx_t - Dual_t}{\|\Delta \vec{g}_t\|^2}$$

Где $Dual_t$ — текущее значение двойственной функции, $Approx_t$ — оценка оптимума двойственной функции.

$$Approx_t = BestDual_t + \delta_t,$$

где $BestDual_t$ — лучшее на данный момент значение двойственной функции,


$$\delta_{t+1} = \begin{cases} \gamma_0 \delta_t, & Dual_t > Dual_{t-1}, \\ \max(\gamma_1 \delta_t, \epsilon) & Dual_t \leq Dual_{t-1}. \end{cases} \quad (1)$$

$\gamma_0, \gamma_1, \epsilon$ — параметры метода, выбранные нами эмпирически.


$$\gamma_0 = 1.5$$

$$\gamma_1 = 0.5$$


$$\epsilon_t = \frac{1}{t}$$




(a) $\alpha_t = 0.1$



(b) $\alpha_t = 0.3$



(c) $\alpha_t = 1$






Рис. 1: Итоговая разметка

Список литературы

- [1] Alahari K., Kohli P., Torr P. H. S. Dynamic Hybrid Algorithms for MAP Inference in Discrete MRFs // IEEE Trans. Pattern Anal. Mach. Intell., 2010. — С. 1846–1857.
- [2] Komodakis N., Paragios N., Tziritas G. MRF energy minimization and beyond via dual decomposition // Pattern Analysis and Machine Intelligence, IEEE Transactions on, 2011. — С. 531–552.
- [3] Kappes J. H. A Bundle Approach To Efficient MAP-Inference by Lagrangian Relaxation // Computer Vision and Pattern Recognition (CVPR), IEEE Conference 2012. — С. 1688–1695.